

Multi-scale analysis of lead-lag relationships in high-frequency financial markets

Réplication méthodologique et application sur données 2025–2026

Léo Renault Théo Verdelhan Ziad El Arari

Master 2 – Ingénierie Économique et Financière
Parcours Finance Quantitative
Université Paris-Dauphine – PSL

2026

Auteurs de l'article

Article étudié

Hayashi, T. et Koike, Y. (2020), *Multi-scale analysis of lead-lag relationships in high-frequency financial markets*.

Takaki Hayashi

- ▶ Keio University
- ▶ Graduate School of Business
Administration

Yuta Koike

- ▶ University of Tokyo
- ▶ Graduate School of Mathematical
Sciences

L'article propose un estimateur de lead-lag par échelle de temps, adapté aux données haute fréquence non synchrones.

Plan

- ① Contexte, motivation et contribution de l'étude
- ② Modèle et estimateur Hayashi–Koike
- ③ Implémentation indépendante
- ④ Données et pré-traitements
- ⑤ Validation de l'estimateur
- ⑥ Résultat central : même actif, deux venues
- ⑦ Comparaisons et extensions
- ⑧ Limites et conclusion

Plan

- 1 Contexte et motivation
- 2 Méthode HK
- 3 Implémentation
- 4 Données
- 5 Validation
- 6 Résultat central
- 7 Comparaisons et extensions
- 8 Limites et conclusion

Introduction : réplication + objectifs

- ▶ Le papier étudie le **lead-lag** : un marché ou un actif peut incorporer l'information avant un autre.
- ▶ En haute fréquence, ce n'est pas un simple problème de corrélation :
 - les observations ne sont pas synchrones ;
 - les prix sont bruités par la microstructure ;
 - le lag peut changer selon l'horizon observé.
- ▶ Notre objectif : réimplémenter l'estimateur de manière autonome, puis l'appliquer à des données récentes exploitables.

Question économique

Question du papier

Le leader est-il le même à très court horizon et à horizon un peu plus long ?

- ▶ À l'échelle sub-millisecondes : latence, ordre des quotes, conventions d'horodatage.
- ▶ À l'échelle millisecondes / secondes : arbitrage, découverte de prix, réaction du carnet.
- ▶ Un estimateur unique peut mélanger ces mécanismes.

Apport HK : estimer un lag θ_j différent pour chaque échelle j .

Limites de l'interpolation

Interpolation sur grille

Interpoler les deux prix sur une grille régulière, puis calculer une corrélation retardée.

- ▶ On fabrique des prix qui n'ont pas été réellement observés.
- ▶ Le résultat dépend fortement du pas de grille choisi.
- ▶ À haute fréquence, l'effet Epps et le bid-ask bounce peuvent dominer le signal.

HK évitent cette étape : ils travaillent directement avec les intervalles d'observation.

Apport de Hayashi–Koike

- ▶ **Hayashi–Yoshida** : mesurer une covariance sans imposer une grille commune.
- ▶ **Ondelettes** : séparer le signal par bandes de fréquence.
- ▶ **Argmax par échelle** : extraire un lead-lag $\hat{\theta}_j$ pour chaque horizon.

Idée clé

HK ne cherchent pas “le” lead-lag. Ils cherchent une courbe de lead-lag selon l’échelle.

Où se place le papier dans le cours

Notion du cours	Utilisation dans HK
Ondelettes, Daubechies	Filtre passe-bande pour isoler les échelles.
Covariance multirésolution	Point de départ : covariance par échelle.
Lead-lag multi-échelle	HK formalise l'argmax du lag au lieu d'un décalage manuel.
Microstructure HF	Non-synchronicité, latence, quote vs trade.

Plan

- 1 Contexte et motivation
- 2 Méthode HK**
- 3 Implémentation
- 4 Données
- 5 Validation
- 6 Résultat central
- 7 Comparaisons et extensions
- 8 Limites et conclusion

Modèle : une corrélation différente par échelle

HK modélisent deux Brownien corrélés, avec une densité cross-spectrale par bandes :

$$f_N(\lambda) = \sum_{j=1}^{N+1} R_j e^{-i\lambda\theta_j} 1_{\Lambda_{N-j+1}}(\lambda).$$

- ▶ R_j : intensité de dépendance à l'échelle j .
- ▶ θ_j : décalage temporel à cette échelle.
- ▶ Les log-prix observés peuvent avoir une volatilité stochastique :

$$X_t^\nu = X_0^\nu + \int_0^t \sigma_s^\nu dB_s^\nu.$$

Étape 1 : covariance Hayashi–Yoshida laggée

Pour un lag τ , on décale la deuxième série et on somme les produits d'incrément qui se chevauchent :

$$\hat{U}_N(\tau) = \sum_{I \in \mathcal{O}^1, J \in \mathcal{O}^2} \Delta X^1(I) \Delta X^2(J) 1_{I \cap (J+\tau) \neq \emptyset}.$$

- ▶ C'est la brique qui gère la non-synchronicité.
- ▶ Aucun previous-tick obligatoire.
- ▶ Dans notre code : $\hat{\theta}_j > 0$ signifie que la série 2 leade la série 1.

Étape 2 : filtrer par ondelette

À chaque échelle j , HK filtrent la covariance laggée :

$$\hat{\Gamma}_j(\tau) = \sum_{\ell} \hat{U}_N(\tau - \ell \Delta_N) \Psi_j(\ell).$$

- ▶ Ψ_j est l'autocorrélation d'un filtre de Daubechies.
- ▶ Δ_N fixe la résolution des lags et les bandes temporelles.

Étape 3 : récupérer le lag

Le lag estimé à l'échelle j est le maximum du contraste :

$$\hat{\theta}_j = \arg \max_{\tau \in G_N} |\hat{\Gamma}_j(\tau)|.$$

HRY single-scale

- ▶ un seul lag ;
- ▶ plus simple à lire ;
- ▶ peut annuler deux effets opposés.

HK multi-échelle

- ▶ un lag par j ;
- ▶ sépare plusieurs horizons ;
- ▶ plus proche du message du papier.

Résultat empirique du papier HK

HK appliquent leur méthode à 108 actions du NASDAQ-100, août 2015, en comparant pour chaque action NASDAQ et BATS.

Échelles fines	Pic positif autour de $+0.2$ à $+0.3$ ms : NASDAQ leade BATS, proche du mécanisme DS.
Échelles plus larges	Distribution plus hétérogène, souvent négative : BATS leade NASDAQ sur une partie du panel, proche du mécanisme HRY.

Le point important n'est pas "NASDAQ gagne" ou "BATS gagne", mais la séparation de deux mécanismes à deux horizons.

Plan

- 1 Contexte et motivation
- 2 Méthode HK
- 3 Implémentation**
- 4 Données
- 5 Validation
- 6 Résultat central
- 7 Comparaisons et extensions
- 8 Limites et conclusion

Contrôle de signe

Test synthétique

On construit deux séries où la série 1 leade la série 2 de +3 secondes.

L'estimateur retourne :

$$\hat{\theta}_{\text{HY}} \simeq -3, \quad \hat{\theta}_{\text{HK}} \simeq -3.$$

- ▶ Convention interne : $\hat{\theta}_j < 0 \Leftrightarrow$ série 1 leade série 2.
- ▶ Donc $\hat{\theta}_j > 0 \Leftrightarrow$ série 2 leade série 1.

Plan

- 1 Contexte et motivation
- 2 Méthode HK
- 3 Implémentation
- 4 Données**
- 5 Validation
- 6 Résultat central
- 7 Comparaisons et extensions
- 8 Limites et conclusion

Exigence de données

- ▶ Consigne du projet : travailler sur données réelles, idéalement 2025–2026.
- ▶ Problème : le protocole exact HK est difficilement accessible publiquement :
 - quotes NASDAQ/BATS ;
 - micro-prices ;
 - timestamps SIP et participant ;
 - panel complet d'août 2015.
- ▶ Choix pratique : garder la méthode HK et utiliser des données haute fréquence disponibles.

Papier HK vs notre périmètre de données

	Hayashi-Koike	Application locale
Actifs	108 actions NASDAQ-100	Crypto (BTC, ETH)
Setup	Même action, NASDAQ vs BATS	Cross-venue / cross-product / cross-asset
Prix	Micro-prices de quotes	Trades crypto (aggTrades)
Période	Août 2015	Principalement 2025–2026
Résolution	~ 0.1 ms	50 ms (crypto)

Sources de données

Source	Format	Usage
Binance Vision	aggTrades, parquet cache	Spot, USDT-M perp, COIN-M perp.
Bybit archive	CSV.gz trades	Cross-exchange spot.
Kraken REST	trades paginés	Cross-exchange spot, même asset.
Hyperliquid live	snapshots L2	Piste future pour vrais micro-prices crypto.

Toutes les sources sont transformées en un même objet : deux séries de log-prix non synchrones.

Prix : transaction vs micro-price

- ▶ HK utilisent un micro-price de carnet :

$$p^{micro} = \frac{p^{ask} V^{bid} + p^{bid} V^{ask}}{V^{bid} + V^{ask}}.$$

- ▶ Sur crypto historique public, le carnet complet est souvent absent ou payant.
- ▶ On utilise donc le **log-prix de transaction** (aggTrades) comme prix.

Pré-traitements

- 1 Télécharger ou lire les fichiers bruts par jour.
- 2 Convertir les timestamps en secondes Unix.
- 3 Détecter automatiquement les timestamps Binance en ms ou μs .
- 4 Trier et dédupliquer les timestamps répétés.
- 5 Passer les prix en log-prix.
- 6 Construire une `NonSyncSeries` commune à tous les estimateurs.

Point important

Δ_N ne sert pas à interpoler les prix : il sert à définir la grille de lags et les échelles wavelet.

Même méthode, horizons différents

Échelle	HK 2020	Notre application
$j = 1$	0.2–0.4 ms	0.10–0.20 s
$j = 4$	1.6–3.2 ms	0.80–1.60 s
$j = 6$	6.4–12.8 ms	3.20–6.40 s
$j = 8$	–	12.80–25.60 s

Lecture

On conserve la logique multi-échelle de HK, mais pas le régime ultra-millisecondes du papier.

Non-synchronicité du cas central

BTC, avril 2026

	Trades	Inter-tick médian
Binance	12.6 M	32.5 ms
Kraken	0.86 M	1.39 s

Conséquence

Le ratio de cadence médian est d'environ $43\times$.
Un alignement sur grille donnerait beaucoup de
prix artificiels côté Kraken.

Plan

- 1 Contexte et motivation
- 2 Méthode HK
- 3 Implémentation
- 4 Données
- 5 Validation**
- 6 Résultat central
- 7 Comparaisons et extensions
- 8 Limites et conclusion

Validation : trois contrôles

Contrôle	Vérité injectée	Résultat	Rôle
Signe HY/HK Monte Carlo db10 Densité de ticks	Série 1 mène série 2 de +3 s (1, 1, 2, 2, 3, 5, 7, 10) Δ_N Sous-échantillonnage asymétrique	$\hat{\theta} \simeq -3.00$ s $j = 1..4$ bien récupérés 15/16 cellules gardent le bon signe	Convention Méthode HK Artefact simple

Convention affichée

Dans nos tableaux, $\hat{\theta}_j < 0$ signifie que la série 1 mène la série 2 ; $\hat{\theta}_j > 0$ signifie que la série 2 mène la série 1.

Monte Carlo : portée de la validation

- ▶ Le papier valide l'estimateur sur $n = 30000$ et 1000 trajectoires.
- ▶ Notre simulation est plus légère : $n = 8192$, 20 trajectoires.
- ▶ Ce qu'il valide correctement : les échelles fines et l'avantage du non-synchrone sur l'interpolation.
- ▶ Ce qu'on ne revendique pas : une reproduction numérique des Tables 2–3 du papier.


Positionnement

La validation sert à vérifier la mécanique de l'estimateur avant les données réelles.

Plan

- 1 Contexte et motivation
- 2 Méthode HK
- 3 Implémentation
- 4 Données
- 5 Validation
- 6 Résultat central**
- 7 Comparaisons et extensions
- 8 Limites et conclusion

BTC Binance/Kraken : le résultat central




Avril 2026

Même actif, deux venues : le cas le plus proche de NASDAQ/BATS.

j	Horizon	$\hat{\theta}_j$
1	0.1–0.2 s	-0.05 s
4	0.8–1.6 s	-0.30 s
6	3.2–6.4 s	-0.80 s
8	12.8–25.6 s	-1.95 s

Lecture : Binance mène Kraken, et l'amplitude augmente avec l'échelle.

Robustesse temporelle




Mois	$\hat{\theta}_6$	$\hat{\theta}_8$
Jan. 2026	-0.80 s	-2.00 s
Fév. 2026	-0.55 s	-1.15 s
Avr. 2026	-0.80 s	-1.95 s

Résultat

La direction est stable : $\hat{\theta}_j < 0$ sur les trois mois.

La magnitude est plus faible en février : effet de régime, pas inversion du signal.

Panel 30 jours : trois régularités



- 1 Binance mène Kraken sur BTC et ETH.
- 2 USDT-M mène COIN-M sur le perp BTC.
- 3 Le perpétuel mène le spot sur BTC et ETH.

Synthèse



Le signal le plus propre reste le cross-venue même actif.

Plan

- 1 Contexte et motivation
- 2 Méthode HK
- 3 Implémentation
- 4 Données
- 5 Validation
- 6 Résultat central
- 7 Comparaisons et extensions**
- 8 Limites et conclusion

HK vs HRY : apport du multi-échelle

BTC vs ETH 168h — HK multi-scale révèle ce que HRY single-scale manque




Exemple BTC/ETH

HRY renvoie un lag global proche de zéro.


HK sépare les échelles : le profil apparaît seulement après filtrage wavelet.

C'est l'argument méthodologique principal du papier.

Extension : perpétuel vs spot




BTC : $\hat{\theta}_8 = +0.35$ s



ETH : $\hat{\theta}_8 = +0.40$ s

Lecture : série 1 = spot, série 2 = perpétuel ; $\hat{\theta} > 0$ signifie que le perpétuel mène le spot.

Extension : BTC/ETH cross-asset (exploratoire)



Sur aggTrades, ETH semble mener BTC aux échelles grossières : $\hat{\theta}$ croît de +50 à +250 ms ($j = 4$ à 8).

Plan

- 1 Contexte et motivation
- 2 Méthode HK
- 3 Implémentation
- 4 Données
- 5 Validation
- 6 Résultat central
- 7 Comparaisons et extensions
- 8 Limites et conclusion**

Limites

Point	Conséquence
Prix	Trades crypto au lieu des micro-prices de quotes HK.
Résolution	$\Delta_N = 50$ ms : nos échelles vivent en secondes, pas en micro-latence.

Conclusion

- ❶ L'estimateur HK est réimplémenté : HY laggé, ondelette db10, argmax par échelle.
- ❷ Le résultat central : Binance mène Kraken sur BTC, de -50 ms à -1.95 s selon l'échelle.
- ❸ Le multi-échelle apporte quelque chose : HRY peut renvoyer zéro là où HK révèle un profil.
- ❹ Extension : perpétuel vs spot solide, BTC/ETH exploratoire.